Relatório Técnico: Web Scraper Portal da Transparência

Arquitetura da Solução

Stack Principal

Backend:

- **Django**: Framework web robusto escolhido pela sua maturidade, facilidade de configuração de APIs e amplo ecossistema.
- **Django REST Framework**: Extensão para construção de APIs com serialização automática e validação de dados.
- **Celery**: Sistema de filas de tarefas distribuídas para processamento assíncrono.

Web Scraping:

- **Playwright**: Ferramenta de automação de navegador escolhida por sua capacidade de lidar com JavaScript moderno e detecção anti-bot avançada.

Infraestrutura:

- **Redis**: Broker de mensagens para Celery, oferecendo alta performance e simplicidade de configuração.
- **Docker/Docker Compose**: Conteinerização para padronização de ambiente e facilidade de deployment.
- **Railway**: Plataforma de deployment em nuvem para ambiente de produção.

Decisões Arquiteturais

A escolha arquitetural principal foi a adoção do Celery.

Ela foi motivada pela natureza lenta do web scraping. Operações que podem levar 90-180 segundos não podem ser executadas de forma síncrona em uma API sem comprometer a estabilidade do sistema.

Com esse setup, configuramos um worker que utiliza o prefork pool, modelo no qual cada processo filho (slot de concorrência) é executado de forma independente. O número de slots é, por padrão, igual ao número de núcleos de CPU disponíveis, permitindo o processamento paralelo de múltiplas tarefas.

Isso nos permite ter um equilíbrio entre a estabilidade e a disponibilidade do sistema, o que é especialmente importante num ambiente de produção limitado como o free trial do Railway que estamos usando para produção (512 MB de RAM, 1 GB de disco e 2 vCPU).

Além disso, com o Celery, é fácil montar uma fila de tarefas, o que garante que toda solicitação será eventualmente tratada, mesmo que os recursos disponíveis não permitam realizá-la no momento.

Para o Celery funcionar, ele precisa de um message broker para enfileirar as tarefas e, opcionalmente, um result backend para armazenar os resultados dessas tarefas. O Redis é usado para ambas as funções por sua velocidade e eficiência, agindo como um intermediário super rápido onde o Celery deposita as tarefas a serem executadas e de onde os "workers" do Celery as pegam para processar, além de poder guardar o que aconteceu com cada tarefa após sua conclusão.

Desafios Técnicos Enfrentados

1. Evasão de Detecção Anti-Bot

O Portal da Transparência implementa mecanismos de detecção de automação que podem bloquear requests automatizados. Tive problemas com o bloqueio imediato no acesso e com captchas. Então foram necessárias algumas soluções para “humanizar” o processo.

Isso não era um problema no modo headed, mas com o modo headless o bloqueio foi imediato.

Solução Implementada:

Randomização de User-Agents

```
   user_agents = [
       "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/120.0.0.0 Safari/537.36",
       "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/119.0.0.0 Safari/537.36",
       "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36 (KHTML, like
Gecko) Chrome/120.0.0.0 Safari/537.36",
       "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:109.0) Gecko/20100101
Firefox/121.0",
   ]
```

Simula acessos de diferentes navegadores e dispositivos, tornando o tráfego mais parecido com o de usuários reais

Script para mascarar automação

```
           stealth_script = """
               Object.defineProperty(navigator, 'webdriver', { get: () => undefined });
               Object.defineProperty(navigator, 'plugins', { get: () => [1, 2, 3] });
               Object.defineProperty(navigator, 'languages', { get: () => ['pt-BR',
'pt', 'en-US', 'en'] });
               window.chrome = { runtime: {} };
               Object.defineProperty(navigator, 'permissions', {
                   get: () => ({ query: () => Promise.resolve({ state: 'granted' }) }),
               });
           """
```

Disfarça características que denunciam a presença de um bot (como navigator.webdriver ou ausência de plugins), fazendo o navegador controlado parecer mais com um navegador usado por humanos.

Delays para simular comportamento humano

```
time.sleep(5)
for char in identifier:
    search_box.type(char, delay=random.uniform(50, 150))
```

2. Paginação Dinâmica e Carregamento Assíncrono

O portal utiliza paginação JavaScript dinâmica que requer navegação através de múltiplas páginas de resultados.

Solução Implementada:

Loop de paginação com detecção de estado

```
while True
...
   next_button = detail_page.locator(
       "#tabelaDetalheValoresSacados_paginate .paginate_button.next button"
   )

   if not next_button.count():
       break

   next_button_parent = detail_page.locator(
       "#tabelaDetalheValoresSacados_paginate .paginate_button.next"
   )
   is_disabled = (
       "disabled"
       in next_button_parent.get_attribute("class")
   )

   if is_disabled:
       break

   next_button.click()
   detail_page.wait_for_timeout(
       random.uniform(1000, 2000)
   )
...
```

Plataforma de Hiperautomação: ActivePieces

Na verdade, o ActivePieces foi a última solução que eu tentei, porque já era familiar com os outros produtos sugeridos (Zapier e Make).

Primeiro, com o Make, descobri que a integração dele com os produtos do Google é bem chata de se fazer, necessita de várias configurações no GCP para fazer funcionar, então deixei ele de lado.

Com o Zapier, achei o funcionamento do webhook dele muito limitado e com algumas características estranhas como a formatação automática do output da API, separando ele em vários campos diferentes que eram difíceis de juntar.

Finalmente, o ActivePieces não teve nenhum desses problemas. Integração fácil, funcionalidades claras e simples. O único empecilho foi ter que tratar o output do formulário utilizado pelo usuário com um script em javascript. Nele, os campos vazios continuam aparecendo, o que não funciona com a API, mas foi uma solução bem simples.

No final, o workflow de hiperautomação ficou dessa maneira:

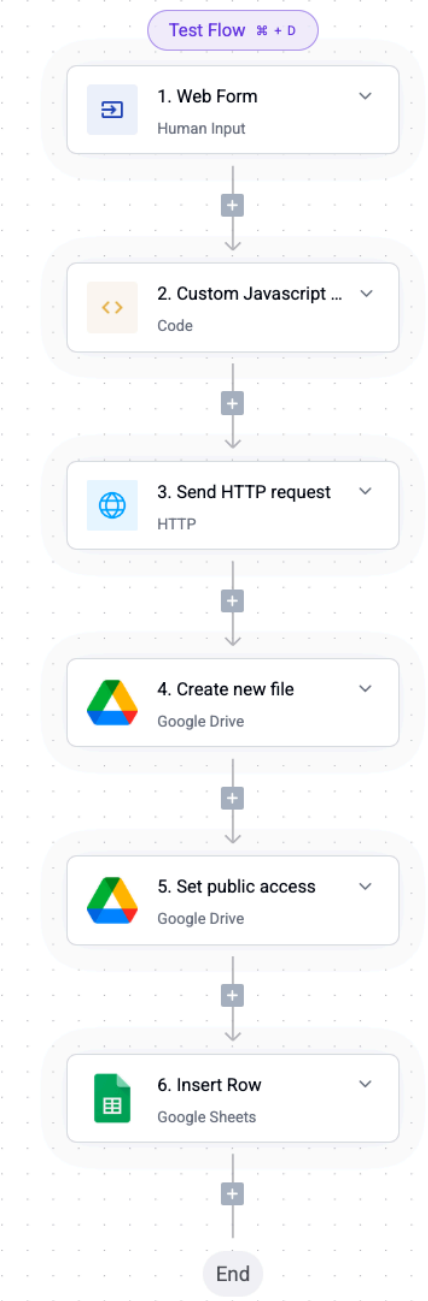
Test Flow ⌘ + D
1. Web Form
Human Input
2. Custom Javascript ...
Code
3. Send HTTP request
HTTP
4. Create new file
Google Drive
5. Set public access
Google Drive
6. Insert Row
Google Sheets
End